apresentacao_orientadores

October 20, 2026

[ ]:
```
import numpy as np
import scipy.stats as st

from matplotlib import pyplot as plt

import arviz as az

from scipy import stats
from scipy.special import logsumexp
from matplotlib.colors import to_hex

from src import StudentTSource
np.random.seed(100)
```

1 Ensaio de sensibilidade local — Separação Cega de Fontes Bayesiana

Notação geral

Símbolo	Significado
$\mathbf{s}(n),\ \mathbf{x}(n),\ n = 1, \dots, N$	fontes e misturas; realização $\mathcal{X} = \{\mathbf{x}(n)\}$
$\underline{\mathbf{A}},\ \underline{\mathbf{B}}$	matrizes verdadeiras de mistura e de separação
$\mathbf{b} = \mathrm{vec}(\mathbf{B}) \in \mathbb{R}^d,\ d = L^2$	vetorização (*flattening*) de $\mathbf{B}$; idem $\underline{\mathbf{b}} = \mathrm{vec}(\underline{\mathbf{B}})$, $\mathbf{i} = \mathrm{vec}(\mathbf{I}_2)$
$p_{s_\ell}(\cdot\,; \xi_s)$	modelo da ℓ-ésima fonte, $\ell = 1, \dots, L$
r_s	distribuição verdadeira das fontes
$p_{\mathbf{b}}(\mathbf{b}; \xi_p),\ p_{\mathbf{B}\mid\mathcal{X}}(\mathbf{B} \mid \mathcal{X})$	distribuições a priori (sobre $\mathbf{b}$) e a posteriori
$\xi_p = (\theta_p,\ \sigma_p,\ \nu_p)$	parâmetros da priori: moda vetorial ($\theta_p \in \mathbb{R}^d$), escala e graus de liberdade
$\xi_s = (\mu_s,\ \sigma_s,\ \nu_s)$	parâmetros do modelo das fontes (verossimilhança): localização, escala e graus de liberdade
$\xi_p^0,\ \xi_s^0$	pontos base; os valores perturbados são indicados por ξ_p^* e ξ_s^*
$\xi_p^a = (\theta_p^a, \sigma_p^a, \nu_p^a),\ \xi_s^a = (\mu_s^a, \sigma_s^a, \nu_s^a),\ a \in \{0, *\}$	parâmetros base (0) e perturbados ($*$); sem sobrescrito, a notação é genérica
$\mathbf{B}_k,\ \mathbf{b}_k = \mathrm{vec}(\mathbf{B}_k),\ k = 1, \dots, K$	amostras MCMC da posteriori base

Símbolo	Significado

1.1 1. Contexto e modelo

Problema: estimar $\mathbf{B}$ a partir de $\mathbf{x}(n) = \underline{\mathbf{A}}\,\mathbf{s}(n)$, com sistema misturador linear, instantâneo e igualmente determinado ($L = M$).

Item	Valor
Fontes / observações	$L = 2$, $N = 1000$
Mistura	$\underline{\mathbf{A}} = \frac{\sqrt{2}}{2}\begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}$ (rotação de 45°)
Separação ideal	$\underline{\mathbf{B}} = \underline{\mathbf{A}}^{-1} = \frac{\sqrt{2}}{2}\begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix}$
Realizações	$R = 25$ (sementes 0–24, as mesmas para todas as fontes)

Log-posteriori normalizada:

$$\frac{1}{N}\log p_{\mathbf{B}|\mathcal{X}}(\mathbf{B} \mid \mathcal{X}; \xi_p, \xi_s) = \log|\det \mathbf{B}| + \frac{1}{N}\sum_{n=1}^{N}\sum_{\ell=1}^{L}\log p_{s_\ell}([\mathbf{B}\mathbf{x}(n)]_\ell; \xi_s) + \frac{1}{N}\log p_{\mathbf{b}}(\mathbf{b}; \xi_p) + \text{cte}, \qquad \mathbf{b} = \text{vec}(\mathbf{B})$$

1.2 2. Fontes consideradas

Para as distribuições das fontes, toma-se como forma funcional a distribuição Student-t com parâmetros de localização e escala: $p_{s_\ell}(s; \xi_s) \sim t(\mu_s,\ \sigma_s,\ \nu_s)$. Assim, tem-se que

$$p_{s_\ell}(s; \xi_s) = \frac{\Gamma\left(\frac{\nu_s+1}{2}\right)}{\Gamma\left(\frac{\nu_s}{2}\right)\sqrt{\nu_s \pi}\,\sigma_s}\left[1 + \frac{1}{\nu_s}\left(\frac{s-\mu_s}{\sigma_s}\right)^2\right]^{-\frac{\nu_s+1}{2}}.$$

São consideradas **dez** distribuições verdadeiras r_s, todas Student-t com:

- $\mu_s^0 = 0$,
- $(\sigma_s^0)^2 = (\nu_s^0 - 2)/\nu_s^0$,
- $\nu_s^0 \in \{3, 4, ..., 12\}$.

Assim, as fontes rs1–rs10 possuem, todas, **variância unitária**, e diferem apenas na forma (peso de cauda e concentração em torno de μ_s). Uma vez que a Student-t é uma generalização da gaussiana, ($t(\cdot) \to N(\cdot)$ à medida que $\nu \to \infty$), a configuração realiza um **controle de gaussianidade das fontes**. A aproximação da distribuição normal se torna progressivamente melhor de rs1 a rs10.

r_s	rs1	rs2	rs3	rs4	rs5	rs6	rs7	rs8	rs9	rs10
ν_s	3	4	5	6	7	8	9	10	11	12
σ_s^2	1/3	1/2	3/5	2/3	5/7	3/4	7/9	4/5	9/11	5/6

Intervalos de Maior Densidade (Highest Density Intervals - HDIs) e Divergência KL em relação à Gaussiana.

Distribuição	HDI de 95%	Variação do HDI vs. gaussiana	$D_{KL}(r_s \,\|\, \mathcal{N}(0,1))$
rs1 ($\nu_s = 3$)	$\pm 1{,}837$	$-6{,}3\%$	0,1948
rs2 ($\nu_s = 4$)	$\pm 1{,}963$	$+0{,}2\%$	0,0838
rs3 ($\nu_s = 5$)	$\pm 1{,}991$	$+1{,}6\%$	0,0468
rs4 ($\nu_s = 6$)	$\pm 1{,}998$	$+1{,}9\%$	0,0299
rs5 ($\nu_s = 7$)	$\pm 1{,}998$	$+2{,}0\%$	0,0208
rs6 ($\nu_s = 8$)	$\pm 1{,}997$	$+1{,}9\%$	0,0153
rs7 ($\nu_s = 9$)	$\pm 1{,}995$	$+1{,}8\%$	0,0117
rs8 ($\nu_s = 10$)	$\pm 1{,}993$	$+1{,}7\%$	0,0092
rs9 ($\nu_s = 11$)	$\pm 1{,}991$	$+1{,}6\%$	0,0075
rs10 ($\nu_s = 12$)	$\pm 1{,}989$	$+1{,}5\%$	0,0062
Gaussiana $\mathcal{N}(0,1)$	$\pm 1{,}960$	0,0%	0

[5]:
```
################
# Plot fontes #
################

# Graus de liberdade e valores x avaliados
evaluated_dfs = range(3,13)
evaluated_x = np.linspace(-5,5,1000)

# Colormap (mesmo padrão dos métodos de IS)
cmap = plt.get_cmap('magma')
colors = cmap(np.linspace(0.0, 0.8, len(evaluated_dfs)))

# Instantiate sources
sources = {str(df): StudentTSource(
    mu=0,
    sigma=np.sqrt((df-2)/df),
    df=df
) for df in evaluated_dfs}

fig, ax = plt.subplots(
    nrows=1, ncols=1,
    figsize=(20,7)
)

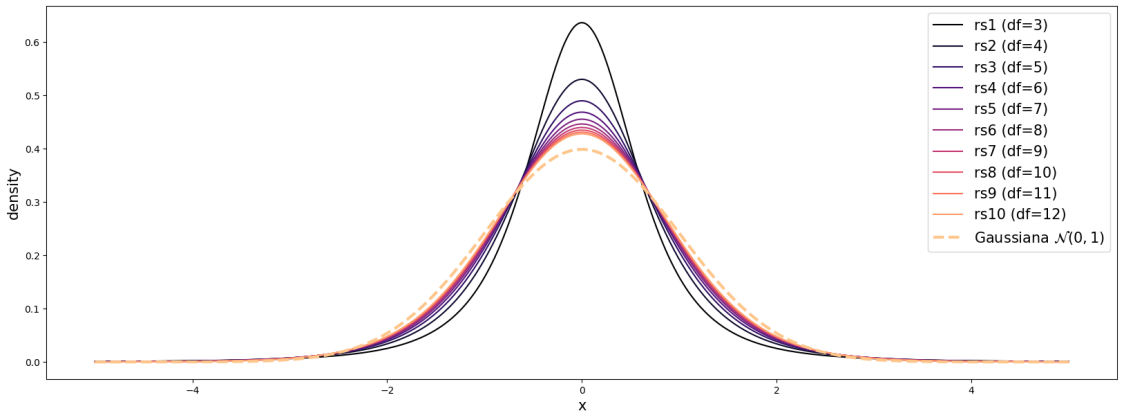
ax.set_xlabel('x', fontsize=15)
```

```
ax.set_ylabel('density', fontsize=15)

# Plot t
for color, (df, s) in zip(colors, sources.items()):
    ax.plot(
        evaluated_x,
        s.get()(evaluated_x),
        color=color,
        label='rs{} (df={})'.format(int(df)-2, df)
    )

# Plot gaussiana N(0,1) com destaque
ax.plot(
    evaluated_x,
    st.norm.pdf(evaluated_x, loc=0, scale=1),
    color=cmap(0.88),
    linestyle='--',
    linewidth=3,
    label=r'Gaussiana $\mathcal{N}(0,1)$',
    zorder=10
)

l = ax.legend(fontsize=15)
```



1.3 3. Priori considerada

Para a distribuição a priori, adota-se como forma funcional distribuição Student-t multivariada sobre $\mathbf{b} = \text{vec}(\mathbf{B}) \in \mathbb{R}^d$, com $d = L^2$ e matriz de covariância $\sigma_p^2 \mathbf{I}_d$. Assim, tem-se $p_{\mathbf{b}}(\mathbf{b}; \xi_p) \sim \mathcal{T}(\theta_p, \sigma_p, \nu_p)$:

$$p_{\mathbf{b}}(\mathbf{b};\xi_p) = \frac{\Gamma\left(\frac{\nu_p+d}{2}\right)}{\Gamma\left(\frac{\nu_p}{2}\right)(\nu_p\pi)^{d/2}\,\sigma_p^d}\left[1+\frac{(\mathbf{b}-\theta_p)^\top(\mathbf{b}-\theta_p)}{\nu_p\,\sigma_p^2}\right]^{-\frac{\nu_p+d}{2}}$$

É a generalização, com cauda pesada, da priori gaussiana usada na Qualificação.

1.4 4. Objetivos científicos e perguntas

Objetivo: quantificar o quanto $p_{\mathbf{B}|\mathcal{X}}$ é sensível a perturbações locais de ξ_p e ξ_s.

Perguntas:

1. **Priori:** quanto os momentos a posteriori de b_{ij} (média, variância, assimetria, curtose) mudam com perturbações em θ_p, σ_p e ν_p?
2. **Modelo das fontes:** quanto os momentos a posteriori de b_{ij} (média, variância, assimetria, curtose) mudam com perturbações em μ_s, σ_s e ν_s?
3. **Efeito de r_s:** a sensibilidade muda ao passar de fontes de cauda pesada (rs1) para fontes quase gaussianas (rs10)?
4. **Priori × verossimilhança:** com $N = 1000$, qual dos dois componentes domina a posteriori?

1.5 5. Importance sampling autonormalizado

A amostragem de importância permite estimar esperanças e momentos sob uma distribuição alvo a partir de amostras de outra distribuição, mais simples de amostrar ou já disponível. A mesma amostra pode ser reutilizada para diferentes funções h e diferentes alvos, ajustando os **pesos de importância**.

Ideia geral e derivação (Paulino et al., 2018, p. 290–291, eq. 7.18 e 7.19): sejam $p^0(\theta)$ a densidade base e $p^*(\theta)$ a densidade alvo, definidas sobre o espaço paramétrico Φ_θ, com $p^0 > 0$. Para uma função integrável h:

$$\begin{aligned}
\mathcal{H}^* &= \mathbb{E}_{p^*}[h(\theta)] \\
&= \int_{\Phi_\theta} h(\theta)\, p^*(\theta)\, \mathrm{d}\theta \\
&= \int_{\Phi_\theta} h(\theta)\, \underbrace{\frac{p^*(\theta)}{p^0(\theta)}}_{w(\theta)}\, p^0(\theta)\, \mathrm{d}\theta \\
&= \mathbb{E}_{p^0}[h(\theta)\, w(\theta)].
\end{aligned}$$

Com $\theta_k \sim p^0$ e $w_k = w(\theta_k)$, a estimativa de Monte Carlo é:

$$\widehat{\mathcal{H}}^*_{\mathrm{IS}} = \frac{1}{K}\sum_{k=1}^{K} h(\theta_k)\, w_k.$$

Na forma autonormalizada, os pesos são divididos pela sua soma:

$$\widehat{\mathcal{H}}^{*}_{\mathrm{IS}} = \frac{\sum_{k=1}^{K} h(\theta_k)\, w_k}{\sum_{k=1}^{K} w_k} = \sum_{k=1}^{K} \tilde{w}_k\, h(\theta_k), \qquad \tilde{w}_k = \frac{w_k}{\sum_{k'=1}^{K} w_{k'}}.$$

Aplicação ao ensaio: amostras $\mathbf{B}_k \sim p_{\mathbf{B}|\mathcal{X}}(\mathbf{B} \mid \mathcal{X}; \xi_p^0, \xi_s^0)$, com $k = 1, \ldots, K$:

$$\hat{\mathbb{E}}_{\xi_p^*, \xi_s^*}[h(\mathbf{B})] = \sum_{k=1}^{K} \tilde{w}_k\, h(\mathbf{B}_k), \qquad \tilde{w}_k = \frac{w_k}{\sum_{k'=1}^{K} w_{k'}}.$$

Pesos brutos w_k:

Posteriori:

$$\log w_k = \log p_{\mathbf{B}|\mathcal{X}}(\mathbf{B}_k \mid \mathcal{X}; \xi_p^*, \xi_s^*) - \log p_{\mathbf{B}|\mathcal{X}}(\mathbf{B}_k \mid \mathcal{X}; \xi_p^0, \xi_s^0).$$

Priori, quando $\xi_s^* = \xi_s^0$ (pesos equivalentes após a autonormalização):

$$\log w_k = \log p_{\mathbf{b}}(\mathbf{b}_k; \xi_p^*) - \log p_{\mathbf{b}}(\mathbf{b}_k; \xi_p^0).$$

Modelo das fontes, quando $\xi_p^* = \xi_p^0$ (pesos equivalentes após a autonormalização):

$$\log w_k = \sum_{n=1}^{N} \sum_{\ell=1}^{L} \Big[\log p_{s_\ell}([\mathbf{B}_k \mathbf{x}(n)]_\ell; \xi_s^*) - \log p_{s_\ell}([\mathbf{B}_k \mathbf{x}(n)]_\ell; \xi_s^0) \Big].$$

O termo $N \log |\det \mathbf{B}_k|$ se cancela.

A soma das diferenças de log-priori e log-verossimilhança fornece os pesos para alterações simultâneas de ξ_p e ξ_s, usados na estimativa autonormalizada.

Quantidades de interesse: média, variância, assimetria e curtose de cada b_{ij}, ponderadas por $\tilde{w}_k$. A média ponderada é a estimativa $\widehat{\mathbf{B}}^{*}_{\mathrm{MMSE}}$ sob (ξ_p^*, ξ_s^*).

1.6 6. Parâmetros perturbados e intervalos

1.6.1 6.1 Variação da priori ($\xi_s^* = \xi_s^0 = r_s$, para cada uma das fontes rs1-rs10)

Perturbação	Base	Alvos	Justificativa do intervalo
Moda θ_p	$\theta_p^0 = \frac{1}{2}(\underline{\mathbf{b}} + \mathbf{i})$, $\sigma_p^0 = \sqrt{1/3}$, $\nu_p^0 = 3$	$\theta_p^*(\alpha) = (1-\alpha)\underline{\mathbf{b}} + \alpha\,\mathbf{i}$, $\alpha \in [0,1]$ (50 pts)	Homotopia da moda da priori, indo da solução ideal à identidade; a base no meio do caminho mantém as duas pontas dentro da faixa de confiabilidade do PSIS.
Escala σ_p	$\theta_p^0 = \underline{\mathbf{b}}$, $\sigma_p^0 = 0{,}5$, $\nu_p^0 = 3$	$\sigma_p^* \in [10^{-1}, 10^{1}]$ (50 pts, log)	Vai de priori informativa a pouco informativa, utilizando os mesmos extremos 0,1 e 10 do experimento da Qualificação; mantém a variação paramétrica dentro da faixa permitida pelo $\hat{k}$ do PSIS.
Cauda ν_p	$\theta_p^0 = \underline{\mathbf{b}}$, $\sigma_p^0 = \sqrt{1/3}$, $\nu_p^0 = 3$	$\nu_p^* \in \{3, \ldots, 29\}$	Vai de cauda pesada até perto da normal, faixa em que os pesos seguem confiáveis segundo o diagnóstico do PSIS.

1.6.2 6.2 Variação do modelo das fontes (priori fixa: $\theta_p^0 = \underline{\mathbf{b}}$, $\sigma_p^0 = \sqrt{1/3}$, $\nu_p^0 = 3$)

Perturbação	Base	Alvos	Justificativa do intervalo
Localização μ_s	$\mu_s^0 = 0$	$\mu_s^* \in [-0{,}2;\ 0{,}2]$ (50 pts)	Faixa ao redor da moda do modelo das fontes base que é indicada como confiável pelo $\hat{k}$ do PSIS.
Escala σ_s	σ_s^0 de r_s	$\sigma_s^* = \sigma_s^0\, e^{u}$, $u \in [-0{,}015;\ 0{,}015]$ ($\pm 1{,}5\%$, 50 pts)	Faixa relativa única, a maior que mantém o $\hat{k}$ do PSIS aceitável para todas as fontes (rs1–rs10).

Perturbação	Base	Alvos	Justificativa do intervalo
Cauda ν_s	ν_s^0 de r_s	$\nu_s^* \in \{3, \dots, 29\}$, $\sigma_s^* = \sigma_s^0$ fixo	Mesma faixa usada na priori, para comparação direta; a confiabilidade é checada pelo $\widehat{k}$ em cada ponto.

Na cauda, $\sigma_s^* = \sigma_s^0$ fica fixo pela mesma lógica adotada para $\sigma_p^* = \sigma_p^0$ na priori.

1.7 7. Metodologia — fluxo geral

Fluxo inspirado no *power-scaling* (Kallioinen et al.): **perturbar priori e verossimilhança separadamente avaliar impactos sobre posteriori-base**. A diferença é que, em vez de usar potências da priori ou da verossimilhança, perturbam-se individualmente os parâmetros em (ξ_p, ξ_s).

```
MCMC na posteriori base ( p  ,  s )

        Varredura da vizinhança de parâmetros: pesos de IS → PSIS → R̂ → momentos ponderados

        Sensibilidade local: Cov(h(B),  ) no ponto base (sem reponderar)

    Comparação: inclinação local × curva de variação local (por fonte, por realização)
```

1.7.1 7.1 Amostragem base — Barker MH (NumPyro)

Substitui o Metropolis-Hastings de passeio aleatório da Qualificação: a proposta usa o gradiente da log-posteriori.

Configuração	Valor
Cadeias / amostras	4 cadeias, $K = 20.000$ amostras finais (5.000 por cadeia)
Aquecimento	5.000 iterações, aceitação-alvo de 0,5
Convergência	$\widehat{R} < 1{,}01$ em todos os b_{ij}, avaliado a cada 500 iterações, 2 avaliações seguidas
Máx. iterações	15.000
Inicialização	$\underline{\mathbf{B}} + \varepsilon$, $\varepsilon_{ij} \sim t_3(0;\, 0{,}05)$

1.8 8. Equacionamento

1.8.1 8.1 PSIS e diagnóstico $\hat{k}$ (Vehtari et al., 2024)

Motivação: quando a posteriori alvo e a base diferem muito em certas regiões, a distribuição dos pesos w_k ganha uma cauda longa. Poucas amostras passam a dominar a estimativa, que fica instável. O PSIS controla essa cauda.

- Ajusta uma Pareto generalizada às $M_{\text{cauda}} = \lfloor \min(0{,}2K,\ 3\sqrt{K}) \rfloor$ maiores razões.
- Substitui essas razões pelas estatísticas de ordem esperadas: $w_{(K-M_{\text{cauda}}+m)} = F^{-1}\left(\frac{m-1/2}{M_{\text{cauda}}}\right)$, $m = 1, \ldots, M_{\text{cauda}}$. As estatísticas de ordem são os valores esperados, sobre os pesos ordenados, da distribuição Pareto ajustada.
- $\hat{k}$ = forma da Pareto ajustada, que indica quantos momentos dos pesos são finitos. $\hat{k} < 0{,}7$ $\rightarrow$ **confiável** (com $K = 20.000$, o limiar é $\min(1 - 1/\log_{10} K,\ 0{,}7) = 0{,}7$).
- Eficiência relativa do MCMC: $R_{\text{eff}} = \text{ESS}_{\min}/K$.

$\rightarrow$ A curva $\hat{k} \times$ parâmetro delimita **a faixa em que a varredura da vizinhança dos parâmetros perturbados vale**.

Quando os pesos de importância têm cauda pesada, poucos valores extremos podem dominar a estimativa, tornando-a muito variável entre realizações. O PSIS substitui os maiores pesos por quantis da Pareto ajustada, reduzindo a variabilidade amostral (ruído amostral) desses extremos e, consequentemente, da estimativa. O objetivo não é diminuir todos os pesos grandes, mas regularizar sua contribuição, com baixo viés, para obter estimativas mais estáveis.

Justificativa da expressão das estatísticas de ordem.

Seja F a CDF da Pareto ajustada à cauda. Se Y segue essa distribuição, a transformação $U = F(Y)$ segue uma Uniforme$(0, 1)$:

$$P(U \leq p) = P(Y \leq F^{-1}(p)) = p, \qquad 0 < p < 1.$$

Como F é crescente, preserva a ordenação dos M_{cauda} valores:

$$Y_{(m)} = F^{-1}(U_{(m)}).$$

O PSIS usa uma aproximação baseada em percentis igualmente espaçados, nos pontos médios de M_{cauda} faixas de probabilidade:

$$p_m = \frac{m - 1/2}{M_{\text{cauda}}} = F^{-1}\left(\frac{m - 1/2}{M_{\text{cauda}}}\right), m = 1, \ldots, M_{\text{cauda}}.$$

Aplicando a inversa da Pareto, esses percentis tornam-se os pesos suavizados:

$$w_{(K-M_{\text{cauda}}+m)} = F^{-1}(p_m).$$

Assim, cada peso observado é substituído pelo quantil da Pareto associado à sua posição na cauda.

[26]:
```
# ------------------------------------------------------------------------
# Configurações
# ------------------------------------------------------------------------

n_curves = 10
x = np.linspace(-0.5, 10, 2000)

# Valores de referência (mantidos fixos quando outro parâmetro varia)
u_ref, k_ref, sigma_ref = 0.0, 0.3, 1.0

# Parâmetros variados em cada subplot
variations = {
    "u": {
        "values": np.linspace(0.5, 4.5, n_curves),
        "label": "Ponto de corte $u$ (localização)",
    },
    "k": {
        "values": np.linspace(-1.0, 1.0, n_curves),
        "label": "Forma $k$",
    },
    "sigma": {
        "values": np.linspace(0.5, 3.0, n_curves),
        "label": r"Escala $\sigma$",
    },
}

cmap = plt.get_cmap("magma")
colors = [
    to_hex(c) for c in cmap(np.linspace(0.10, 0.85, n_curves))
]


# ------------------------------------------------------------------------
# Resumo da configuração
# ------------------------------------------------------------------------

print("#" * 100)
print("DISTRIBUIÇÃO PARETO GENERALIZADA: f(x) = (1/sigma) [1 + k (x-u)/
 ↪sigma]^(-1/k - 1)")
print("#" * 100)
print(f"Valores de referência: u = {u_ref}, k = {k_ref}, sigma = {sigma_ref}")
print("Suporte: x >= u (k >= 0)  |  u <= x <= u - sigma/k (k < 0)")
for name, v in variations.items():
    print(f"{name:<6} varia de {v['values'][0]:.2f} a {v['values'][-1]:.2f} ")
    print(f"({n_curves} curvas)")
print("#" * 100)
```

```
# ------------------------------------------------------------------------
# Visualização
# ------------------------------------------------------------------------

fig, axes = plt.subplots(
    nrows=3, ncols=1,
    figsize=(18, 16)
)

fig.suptitle(
    "Distribuição Pareto generalizada: efeito de cada parâmetro",
    fontsize=22,
    y=0.995
)

for ax, (name, var) in zip(axes, variations.items()):

    for value, color in zip(var["values"], colors):

        u, k, sigma = u_ref, k_ref, sigma_ref
        if name == "u":
            u = value
        elif name == "k":
            k = value
        else:
            sigma = value

        # scipy: c = k (forma), loc = u (corte), scale = sigma (escala)
        pdf = stats.genpareto.pdf(x, c=k, loc=u, scale=sigma)

        ax.plot(
            x, pdf,
            color=color, linewidth=2.5,
            label=f"{name} = {value:.2f}"
        )

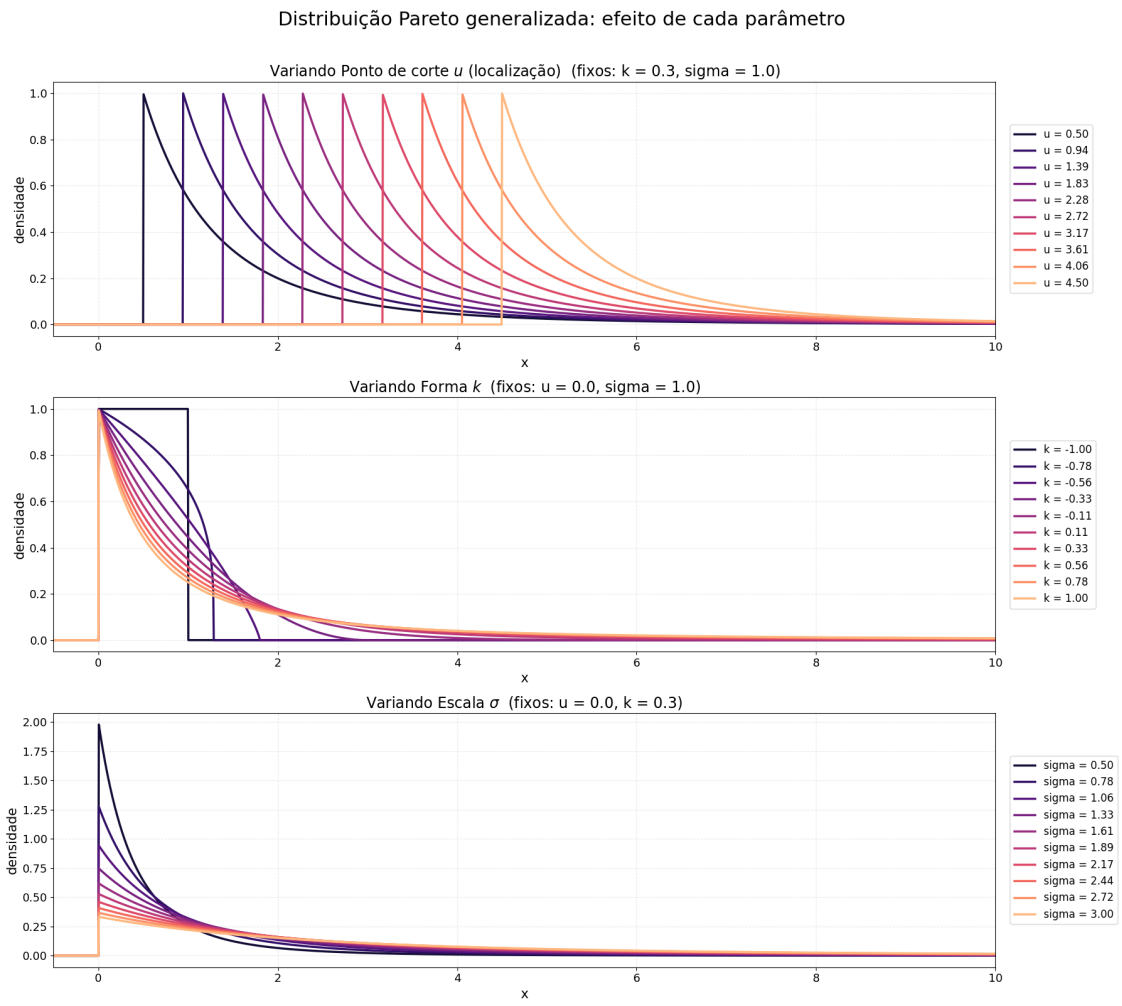
    fixed = {"u": u_ref, "k": k_ref, "sigma": sigma_ref}
    fixed.pop(name)
    fixed_txt = ", ".join(f"{p} = {v}" for p, v in fixed.items())

    ax.set_xlabel("x", fontsize=15)
    ax.set_ylabel("densidade", fontsize=15)
    ax.set_title(
        f"Variando {var['label']}  (fixos: {fixed_txt})",
        fontsize=17
    )
```

```
    ax.set_xlim(x[0], x[-1])
    ax.tick_params(axis="both", labelsize=13)
    ax.grid(alpha=0.25, linestyle="--")
    ax.legend(fontsize=12, loc="center left", bbox_to_anchor=(1.01, 0.5))

plt.tight_layout(rect=[0, 0, 1, 0.98])
plt.show()
```

```
################################################################################
####################
DISTRIBUIÇÃO PARETO GENERALIZADA: f(x) = (1/sigma) [1 + k (x-u)/sigma]^(-1/k -
1)
################################################################################
####################
Valores de referência: u = 0.0, k = 0.3, sigma = 1.0
Suporte: x >= u (k >= 0)  |  u <= x <= u - sigma/k (k < 0)
u      varia de 0.50 a 4.50
(10 curvas)
k      varia de -1.00 a 1.00
(10 curvas)
sigma  varia de 0.50 a 3.00
(10 curvas)
################################################################################
####################
```



[28]:
```
# ------------------------------------------------------------------------
# Configurações
# ------------------------------------------------------------------------

rng = np.random.default_rng(121)

n_samples = 5000
reff = 1.0
log_y = True   # escala logarítmica no eixo y dos gráficos de pesos

# Forma funcional única: log w = k * E, com E ~ Exponential(1).
# Escalar os log-pesos por k equivale a log w ~ Exponential(taxa = 1/k), logo
#   P(w > t) = t^(-1/k)  ->  w ~ Pareto, cauda de Pareto generalizada com forma␣
 ↪k.
#   k maior (escala maior) -> decaimento mais lento  -> cauda mais pesada
#   k menor (escala menor) -> decaimento mais rápido -> cauda mais leve
```

```python
k_values = [-0.25, 0.05, 0.5, 0.6, 1.0]

scenarios = {
    f"Cenário {i}": {"k": k}
    for i, k in enumerate(k_values, start=1)
}

cmap = plt.get_cmap("magma")
colors = [
    to_hex(c) for c in cmap(np.linspace(0.15, 0.80, len(scenarios)))
]


# ------------------------------------------------------------------------
# Funções auxiliares
# ------------------------------------------------------------------------

def generate_log_weights(spec, size, rng):
    """Log-pesos: exponencial padrão escalada por spec['k']."""
    return spec["k"] * rng.exponential(scale=1.0, size=size)


def psis_tail_length(size, reff=1.0):
    """Número de pesos na cauda suavizada pelo PSIS."""
    return int(np.ceil(min(size / 5, 3 * np.sqrt(size / reff))))


# ------------------------------------------------------------------------
# Resumo da configuração do estudo
# ------------------------------------------------------------------------

tail_length = psis_tail_length(n_samples, reff)

print("#" * 100)
print("CONFIGURAÇÃO DA SIMULAÇÃO: PSIS SOBRE PESOS DE IMPORTÂNCIA SINTÉTICOS")
print("#" * 100)
print(f"Amostras:         K = {n_samples}  (reff = {reff})")
print(f"Cauda do PSIS:    M = {tail_length} maiores pesos "
      f"({100 * tail_length / n_samples:.1f}% da amostra)")
print(f"Suavização:       Pareto generalizada ajustada à cauda (arviz.psislw)")
print("-" * 100)
print("Geração dos pesos brutos (forma funcional única):")
print("  log w = k * E, com E ~ Exponencial(1)")
print("  Escala maior (decaimento mais lento) -> cauda mais pesada -> k maior.")
print("  Escala menor (decaimento mais rápido) -> cauda mais leve -> k menor.")
print("#" * 100)
print("Leitura: k-hat < 0,5 (leve); 0,5-0,7 (limiar); > 0,7 (pouco confiável).")
```

```
print()


# ------------------------------------------------------------------------
# Simulação e aplicação do PSIS
# ------------------------------------------------------------------------

results = {}

for scenario, spec in scenarios.items():

    raw_log_weights = generate_log_weights(spec, n_samples, rng)

    # PSIS: log-pesos suavizados (normalizados) e k-hat
    smoothed_log_weights, k_hat = az.psislw(raw_log_weights.copy(), reff=reff)

    # Pesos brutos normalizados e pesos suavizados
    raw_weights = np.exp(raw_log_weights - logsumexp(raw_log_weights))
    smoothed_weights = np.exp(smoothed_log_weights)

    results[scenario] = {
        "k_true": spec["k"],
        "k_hat": float(k_hat),
        "raw_sorted": np.sort(raw_weights),
        "smoothed_sorted": np.sort(smoothed_weights),
        "tail_length": tail_length,
    }


# ------------------------------------------------------------------------
# Visualização
# ------------------------------------------------------------------------

fig, axes = plt.subplots(
    nrows=len(results), ncols=3,
    figsize=(30, 24)
)

fig.suptitle(
    "Suavização de Pareto dos pesos de importância",
    fontsize=24,
    y=0.995
)

ranks = np.arange(1, n_samples + 1)   # posição a partir do menor peso

for row, ((scenario, r), color) in enumerate(zip(results.items(), colors)):
```

```
    ax_w, ax_tail, ax_ratio = axes[row]
    M = r["tail_length"]

    # ---- Painel esquerdo: pesos ordenados do menor para o maior (log-log) -
    ax_w.scatter(
        ranks, r["raw_sorted"],
        s=18, color=color, alpha=0.5,
        label="Pesos brutos"
    )
    ax_w.plot(
        ranks, r["smoothed_sorted"],
        color=color, linewidth=3,
        label="Pesos suavizados (PSIS)"
    )
    ax_w.axvline(
        n_samples - M,
        color="black", linestyle="--", linewidth=1.8,
        label=f"Início da cauda suavizada (M={M})"
    )

    ax_w.set_xscale("log")
    if log_y:
        ax_w.set_yscale("log")

    ax_w.set_xlabel("Posição a partir do menor peso", fontsize=15)
    ax_w.set_ylabel("Peso normalizado", fontsize=15)
    ax_w.set_title(
        "Pesos normalizados e ponto de corte: "
        rf"$\widehat{{k}}={r['k_hat']:.2f}$",
        fontsize=17
    )
    ax_w.tick_params(axis="both", labelsize=13)
    ax_w.grid(alpha=0.25, linestyle="--")
    ax_w.legend(fontsize=12, loc="upper left")

    # ---- Painel central: mesmos pesos, restrito à cauda (eixo x linear) --
    tail_ranks = ranks[-M:]

    ax_tail.scatter(
        tail_ranks, r["raw_sorted"][-M:],
        s=24, color=color, alpha=0.5,
        label="Pesos brutos"
    )
    ax_tail.plot(
        tail_ranks, r["smoothed_sorted"][-M:],
        color=color, linewidth=3,
```

```
        label="Pesos suavizados (PSIS)"
    )

    if log_y:
        ax_tail.set_yscale("log")

    ax_tail.set_xlabel("Posição a partir do menor peso", fontsize=15)
    ax_tail.set_ylabel("Peso normalizado", fontsize=15)
    ax_tail.set_title(
        "Pesos na cauda suavizada: "
        rf"$\widehat{{k}}={r['k_hat']:.2f}$",
        fontsize=17
    )
    ax_tail.tick_params(axis="both", labelsize=13)
    ax_tail.grid(alpha=0.25, linestyle="--")
    ax_tail.legend(fontsize=12, loc="upper left")

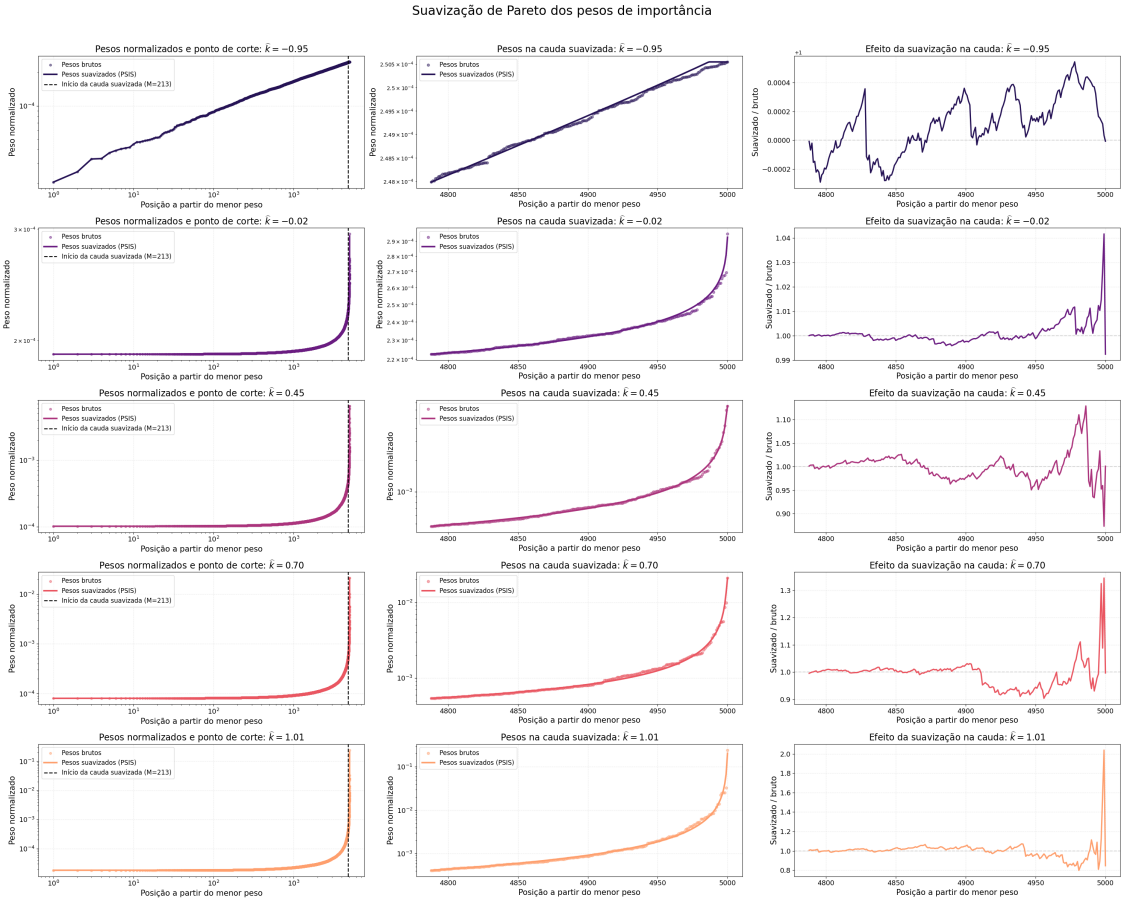
    # ---- Painel direito: razão suavizado / bruto na cauda ---------------
    ax_ratio.axhline(1, color="lightgray", linestyle="--")
    ax_ratio.plot(
        tail_ranks, r["smoothed_sorted"][-M:] / r["raw_sorted"][-M:],
        color=color, linewidth=2.5
    )

    ax_ratio.set_xlabel("Posição a partir do menor peso", fontsize=15)
    ax_ratio.set_ylabel("Suavizado / bruto", fontsize=15)
    ax_ratio.set_title(
        "Efeito da suavização na cauda: "
        rf"$\widehat{{k}}={r['k_hat']:.2f}$",
        fontsize=17
    )
    ax_ratio.tick_params(axis="both", labelsize=13)
    ax_ratio.grid(alpha=0.25, linestyle="--")

plt.tight_layout(rect=[0, 0, 1, 0.98])
plt.show()
```

```
################################################################################
####################
CONFIGURAÇÃO DA SIMULAÇÃO: PSIS SOBRE PESOS DE IMPORTÂNCIA SINTÉTICOS
################################################################################
####################
Amostras:         K = 5000  (reff = 1.0)
Cauda do PSIS:    M = 213 maiores pesos (4.3% da amostra)
Suavização:       Pareto generalizada ajustada à cauda (arviz.psislw)
--------------------------------------------------------------------------------
--------------------
Geração dos pesos brutos (forma funcional única):
```

```
  log w = k * E, com E ~ Exponencial(1)
  Escala maior (decaimento mais lento) -> cauda mais pesada -> k maior.
  Escala menor (decaimento mais rápido) -> cauda mais leve -> k menor.
################################################################################
####################
Leitura: k-hat < 0,5 (leve); 0,5-0,7 (limiar); > 0,7 (pouco confiável).
```



1.8.2 8.2 Sensibilidade local (Pérez, Martín & Rufo, 2006)

As derivadas parciais de uma quantidade a posteriori em relação ao parâmetro perturbado podem ser estimadas por Monte Carlo usando as próprias amostras da posteriori base, sem nova amostragem.

8.2.1 Identidade geral e estimador MCMC Seja $\mathcal{H}(\xi) = \mathbb{E}_\xi[h(\mathbf{B})]$, em que ξ representa os parâmetros da priori e do modelo das fontes, e ξ_j é o componente perturbado. Considerando h fixa, sem dependência explícita de ξ, tem-se:

$$\left[\frac{\partial \mathcal{H}}{\partial \xi_j}\right]_{\xi=\xi^0} = \mathbb{E}_0\left[(h(\mathbf{B}) - \mathcal{H}^0)\eta_{\xi_j}(\mathbf{B})\right] = \mathrm{Cov}_0\left(h, \eta_{\xi_j}\right).$$

O índice 0 indica que as esperanças e covariâncias são calculadas sob a posteriori base.

O escore da posteriori é a derivada parcial de sua log-densidade em relação ao parâmetro perturbado:

$$\eta_{\xi_j}(\mathbf{B}) = \left[\frac{\partial \log p_{\mathbf{B}|\mathcal{X}}(\mathbf{B} \mid \mathcal{X}; \xi)}{\partial \xi_j}\right]_{\xi=\xi^0}.$$

Para perturbações da priori ou da verossimilhança, podem-se usar os escores abaixo. Eles diferem do escore da posteriori normalizada apenas por uma constante em $\mathbf{B}$, que não altera a covariância.

Perturbação	Escore equivalente na covariância
Priori	$\eta_{\xi_p}(\mathbf{B}) = \left[\frac{\partial \log p_{\mathbf{b}}(\mathbf{b};\xi_p)}{\partial \xi_p}\right]_{\xi_p=\xi_p^0}$, com $\mathbf{b} = \mathrm{vec}(\mathbf{B})$
Modelo das fontes	$\eta_{\xi_s}(\mathbf{B}) = \left[\frac{\partial \log \mathcal{L}_{\mathcal{X}}(\mathbf{B};\xi_s)}{\partial \xi_s}\right]_{\xi_s=\xi_s^0}$

Com $\hat{\mathcal{H}}^0 = K^{-1}\sum_{k=1}^{K} h(\mathbf{B}_k)$, o estimador MCMC correspondente é:

$$\widehat{\left[\frac{\partial \mathcal{H}}{\partial \xi_j}\right]}_{\xi=\xi^0} = \frac{1}{K}\sum_{k=1}^{K}(h(\mathbf{B}_k) - \hat{\mathcal{H}}^0)\eta_{\xi_j}(\mathbf{B}_k).$$

8.2.2 Aplicação à média posterior Neste ensaio, a análise local considera a média posterior de cada elemento b_{ij} da matriz de separação:

$$\bar{b}_{ij}(\xi) = \mathbb{E}_\xi[b_{ij}].$$

Como $h(\mathbf{B}) = b_{ij}$ não depende explicitamente de ξ, sua sensibilidade é:

$$\left[\frac{\partial \bar{b}_{ij}}{\partial \xi_j}\right]_{\xi=\xi^0} = \mathrm{Cov}_0(b_{ij}, \eta_{\xi_j}).$$

Para evitar confusão entre o índice da matriz e o índice do parâmetro perturbado, podemos escrever este último como a:

$$\left[\frac{\partial \bar{b}_{ij}}{\partial \xi_a}\right]_{\xi=\xi^0} = \mathrm{Cov}_0(b_{ij}, \eta_{\xi_a}).$$

Com $\hat{\bar{b}}_{ij}^0 = K^{-1}\sum_{k=1}^{K}[\mathbf{B}_k]_{ij}$, a estimativa é:

$$\left[\widehat{\frac{\partial \bar{b}_{ij}}{\partial \xi_a}}\right]_{\xi=\xi^0} = \frac{1}{K}\sum_{k=1}^{K}([\mathbf{B}_k]_{ij} - \hat{\bar{b}}^0_{ij})\eta_{\xi_a}(\mathbf{B}_k).$$

Essa derivada quantifica a mudança local da média posterior em resposta à variação de um parâmetro da priori ou do modelo das fontes, avaliada no ponto base.

1.8.3 8.3 Escores usados

As expressões abaixo são derivadas das log-densidades em relação aos parâmetros diretamente, mantendo os demais fixos. Para a sensibilidade local, todos os parâmetros são avaliados nos valores base ξ_p^0 e ξ_s^0.

Considera-se uma Student-t de localização μ_s e escala σ_s para as fontes, e uma t multivariada de localização θ_p e matriz de forma $\sigma_p^2\mathbf{I}_d$ para a priori.

Notação:

$$z = \frac{[\mathbf{Bx}(n)]_\ell - \mu_s}{\sigma_s}, \qquad \mathbf{b} = \mathrm{vec}(\mathbf{B}), \qquad \delta^2 = \frac{(\mathbf{b}-\theta_p)^\top(\mathbf{b}-\theta_p)}{\sigma_p^2}, \qquad d = L^2 = 4.$$

Os escores das fontes apresentados na tabela correspondem a uma observação e uma fonte. Para obter o escore da verossimilhança completa, somam-se as contribuições em n e ℓ.

Parâmetro	Escore
μ_s	$\dfrac{(\nu_s+1)z}{\sigma_s(\nu_s+z^2)}$
σ_s	$\dfrac{1}{\sigma_s}\left[-1+\dfrac{(\nu_s+1)z^2}{\nu_s+z^2}\right]$
ν_s	$\dfrac{1}{2}\left[\psi\Big(\dfrac{\nu_s+1}{2}\Big)-\psi\Big(\dfrac{\nu_s}{2}\Big)-\dfrac{1}{\nu_s}-\log\Big(1+\dfrac{z^2}{\nu_s}\Big)+\dfrac{(\nu_s+1)z^2}{\nu_s(\nu_s+z^2)}\right]$
α, com $\partial\theta_p/\partial\alpha = \mathbf{i}-\underline{\mathbf{b}}$	$\dfrac{(\nu_p+d)(\mathbf{b}-\theta_p)^\top(\mathbf{i}-\underline{\mathbf{b}})}{\nu_p\sigma_p^2+(\mathbf{b}-\theta_p)^\top(\mathbf{b}-\theta_p)}$
σ_p	$\dfrac{1}{\sigma_p}\left[-d+\dfrac{(\nu_p+d)\delta^2}{\nu_p+\delta^2}\right]$
ν_p	$\dfrac{1}{2}\left[\psi\Big(\dfrac{\nu_p+d}{2}\Big)-\psi\Big(\dfrac{\nu_p}{2}\Big)-\dfrac{d}{\nu_p}-\log\Big(1+\dfrac{\delta^2}{\nu_p}\Big)+\dfrac{(\nu_p+d)\delta^2}{\nu_p(\nu_p+\delta^2)}\right]$

A função ψ, denominada digama, é definida por:

$$\psi(t) = \frac{d}{dt}\log\Gamma(t) = \frac{\Gamma'(t)}{\Gamma(t)}.$$

1.9 9. Saídas esperadas (por fonte × perturbação × realização)

- Curvas dos 4 momentos de b_{ij} em função do parâmetro perturbado, considerando tanto hiperparâmetros da priori (θ_p^*, σ_p^* e ν_p^*) quanto do modelo das fontes (μ_s^*, σ_s^* e ν_s^*).
- Derivadas locais da média de b_{ij}, no ponto base.
- Curva de $\hat{k} \rightarrow$ região de validade.
- Agregação nas realizações que convergiram, comparando rs1 $\rightarrow$ rs10.

1.10 10. Posicionamento metodológico (1 slide)

Abordagem	Tipo	Uso no ensaio
Pérez et al. (2006)	Local, paramétrica, mesma amostra MCMC	**Sim** — derivadas e MCSE
PSIS (Vehtari et al., 2024)	Reponderação estabilizada + diagnóstico	**Sim** — varreduras globais e $\hat{k}$
Power-scaling (Kallioinen et al.)	Local, perturbação por potências da priori/verossimilhança	**Fluxo** (priori e verossimilhança separadas)
REPS (Ho, 2023)	Global, não paramétrica (bola de KL)	Não — referência para limitações das análises locais